

Model			gemma-3-1b-it		gemma-3-4b-it		gemma-3-12b-it		gemma-3-27b-it		Qwen3-1.7B		Qwen3-4B		Qwen3-14B		Qwen3-32B	
Experiment			healthy_to_toxic	toxic_to_healthy	healthy_to_toxic	toxic_to_healthy	healthy_to_toxic	toxic_to_healthy	healthy_to_toxic	toxic_to_healthy	healthy_to_toxic	toxic_to_healthy	healthy_to_toxic	toxic_to_healthy	healthy_to_toxic	toxic_to_healthy	healthy_to_toxic	toxic_to_healthy
Group	Probe	Dataset																
a	LRProbe	hate	0.31	0.53	0.02	0.42	-0.05	0.13	-0.09	0.09	0.03	0.02	-0.0	0.02	-0.0	0.02	0.01	-0.14
	LRProbe	hate_cmplx	-0.19	-1.06	0.03	0.96	-0.04	0.06	-0.4	0.13	0.04	0.08	-0.0	-0.09	-0.0	-0.01	-0.06	0.06
	LRProbe	hate_simpl	-0.36	-2.83	0.03	0.18	-0.08	0.14	-0.16	0.15	0.03	0.01	-0.0	0.03	-0.0	-0.01	-0.04	0.5
	MMProbe	hate	1.31	-2.83	-0.32	1.15	-0.06	0.05	-0.37	0.8	0.13	-0.12	0.01	0.11	-0.0	0.03	-0.03	0.66
	MMProbe	hate_cmplx	0.11	-7.22	-1.24	4.09	-0.38	-0.13	-0.45	3.25	0.07	0.08	0.03	0.28	-0.0	0.75	-0.01	0.17
	MMProbe	hate_simpl	4.61	-2.17	-0.21	0.49	-0.07	0.1	-0.46	0.36	0.16	-0.16	0.0	0.13	-0.0	0.12	0.03	-0.12
b2	LRProbe	hate	-0.06	-0.11	0.37	0.45	-0.04	0.43	-0.13	1.42	0.07	0.19	0.0	0.07	-0.0	0.22	0.02	0.15
	LRProbe	hate_cmplx	-0.08	-0.08	0.2	0.61	-0.04	0.84	-0.27	1.89	0.12	0.52	0.02	0.4	-0.0	0.41	-0.03	0.75
	LRProbe	hate_simpl	-0.03	0.08	-0.09	0.54	0.01	0.67	-0.37	1.1	0.02	0.24	0.0	0.33	0.01	0.65	0.04	0.17
	MMProbe	hate	0.0	0.47	-0.16	0.77	-0.1	0.77	-0.33	1.07	0.56	0.73	0.1	1.0	0.03	0.99	0.03	0.96
	MMProbe	hate_cmplx	0.03	1.03	-0.0	2.2	-0.07	0.73	-0.26	1.06	0.6	0.33	0.01	0.88	0.05	0.91	0.04	0.95
	MMProbe	hate_simpl	-0.17	0.53	-0.07	0.18	-0.08	0.57	-0.31	1.21	0.57	0.82	0.11	1.0	0.07	0.98	0.02	0.92
c	LRProbe	hate	-0.64	-0.31	-0.21	-0.03	-0.1	-0.04	-0.05	0.08	0.02	0.03	0.01	0.27	-0.0	-0.07	0.02	0.01
	LRProbe	hate_cmplx	-0.33	0.17	-0.04	-0.05	0.04	-0.23	-0.15	-0.11	0.04	0.11	0.01	0.07	0.0	0.12	0.02	0.04
	LRProbe	hate_simpl	-0.22	-0.72	-0.19	-0.01	0.07	-0.15	-0.14	0.15	-0.0	-0.01	0.03	0.24	0.0	0.08	0.03	0.02
	MMProbe	hate	-0.22	0.42	-0.03	-0.01	0.02	-0.07	0.07	-0.29	0.11	0.31	0.01	0.39	0.0	0.02	0.03	0.01
	MMProbe	hate_cmplx	-0.11	0.56	-0.24	-0.0	-0.05	-0.16	-0.05	-0.15	0.07	-0.1	0.01	0.13	0.0	0.06	0.02	0.01
	MMProbe	hate_simpl	-0.11	0.19	-0.06	-0.01	0.02	-0.08	0.05	-0.15	0.16	0.23	0.01	0.41	0.01	0.02	0.02	0.01