

Model			gemma-3-270m-it		Qwen3-0.6B		gemma-3-4b-it		Qwen3-4B	
Experiment			healthy_to_toxic	toxic_to_healthy	healthy_to_toxic	toxic_to_healthy	healthy_to_toxic	toxic_to_healthy	healthy_to_toxic	toxic_to_healthy
Group	Probe	Dataset								
a	LRProbe	c	0.39	-4.0	-0.07	-0.07	-0.41	0.05	0.0	-0.02
		cn	-0.56	-3.11	-0.04	-0.04	-0.17	-0.01	0.0	-0.0
		g	1.61	-7.0	0.04	0.14	0.19	0.02	-0.0	0.05
		gn	0.78	-5.22	0.07	0.11	0.09	0.17	0.0	0.02
		h	1.06	-0.0	0.14	0.18	0.22	0.63	-0.0	0.03
		hc	1.39	1.94	-0.04	0.14	-0.13	0.77	-0.0	-0.11
		hs	1.89	-0.89	0.07	0.14	-0.0	0.09	-0.0	0.03
	MMProbe	c	0.17	-6.89	-0.04	1.11	-1.47	0.18	0.02	0.41
		cn	1.5	-14.11	-0.18	0.54	-1.21	0.14	0.01	0.25
		g	0.83	-0.0	0.68	1.43	-0.92	-0.02	0.08	0.52
		gn	1.67	-5.56	-0.0	1.14	-0.2	-0.11	0.03	0.37
		h	1.67	-1.56	-0.43	0.75	-0.42	1.14	0.01	0.16
		hc	-2.33	-5.56	0.11	-0.86	-1.31	4.08	0.03	0.35
		hs	4.11	-9.56	-0.14	0.82	-0.25	0.55	0.01	0.16
b1	LRProbe	c	-0.5	-0.72	0.14	0.14	-0.08	-0.05	0.0	-0.01
		cn	0.28	0.22	0.39	0.36	-0.02	-0.01	-0.0	-0.07
		g	0.22	1.0	0.5	0.64	-0.12	0.06	0.01	0.2
		gn	0.39	0.5	0.32	0.0	-0.01	-0.01	-0.0	0.04
		h	0.22	0.28	-0.21	-0.29	-0.14	0.05	0.01	0.31
		hc	-3.0	-4.56	0.68	-0.04	-0.12	0.15	0.05	1.0
		hs	0.67	1.72	-0.0	-0.18	0.05	0.12	0.03	0.33
	MMProbe	c	-1.39	1.67	0.11	-0.75	-0.01	-0.03	0.04	0.17
		cn	-0.28	1.28	-0.04	-1.04	-0.02	-0.07	0.02	-0.31
		g	-0.83	1.0	0.32	0.79	-0.0	0.19	0.05	0.83
		gn	0.28	0.44	0.11	0.39	-0.07	0.04	0.03	0.3
		h	-1.89	-1.5	1.0	0.79	0.22	0.62	0.15	1.01
		hc	-1.39	-0.22	-0.21	0.04	-0.03	0.47	0.02	0.68
		hs	1.33	1.61	1.61	0.39	-0.09	0.46	0.13	1.01
b2	LRProbe	c	0.0	-0.0	0.07	-0.04	0.1	0.2	-0.0	-0.0
		cn	0.0	-0.0	0.04	0.0	0.27	-0.16	-0.0	0.02
		g	0.0	-0.0	0.04	-0.07	0.2	0.05	-0.0	-0.03
		gn	0.0	-0.0	0.04	0.0	0.31	-0.06	-0.0	-0.06
		h	0.0	-0.0	0.14	0.04	0.5	0.83	0.01	0.07
		hc	0.0	-0.0	0.11	0.18	0.36	0.87	0.03	0.44
		hs	0.0	-0.0	0.11	0.11	-0.25	0.25	0.01	0.38
	MMProbe	c	0.0	-0.0	0.18	-0.39	-0.03	0.02	0.01	-0.1
		cn	0.0	-0.0	-0.04	-0.54	-0.06	-0.03	-0.0	-0.16
		g	0.0	-0.0	0.61	0.61	-0.25	-0.03	0.02	0.26
		gn	0.0	-0.0	0.5	0.68	-0.16	-0.35	0.0	-0.03
		h	0.0	-0.0	0.71	1.21	-0.19	0.71	0.09	1.01
		hc	0.0	-0.0	0.54	-0.11	-0.04	2.21	0.02	0.9
		hs	0.0	-0.0	0.89	0.93	-0.1	0.2	0.11	1.01
c	LRProbe	c	0.06	0.78	-0.0	0.0	-0.05	-0.0	0.01	0.09
		cn	1.22	4.06	-0.04	-0.04	-0.03	0.02	0.0	0.16
		g	0.06	2.61	-0.04	-0.04	-0.51	-0.07	-0.0	0.01
		gn	-0.11	3.11	-0.0	0.0	-0.31	0.01	-0.0	-0.09
		h	0.72	2.83	0.07	0.0	-0.21	-0.08	0.01	0.34
		hc	-1.94	6.83	0.04	-0.04	0.02	-0.06	0.01	-0.24
		hs	1.5	2.56	0.11	0.04	-0.12	-0.02	0.02	0.39
	MMProbe	c	60.56	3.56	0.07	0.04	0.14	-0.0	0.01	-0.12
		cn	17.89	3.22	0.07	0.0	0.11	-0.01	0.01	-0.14
		g	7.0	3.56	0.11	-0.04	-0.17	0.0	0.01	0.04
		gn	0.06	2.72	0.14	-0.04	-0.16	0.0	0.01	0.01
		h	-2.5	-10.89	0.07	-0.11	-0.03	-0.01	0.01	0.42
		hc	-4.36	-12.44	0.11	-0.04	-0.25	0.01	0.01	0.16
		hs	-4.42	0.89	0.39	-0.04	-0.06	0.0	0.01	0.44