

Model			Qwen3-0.6B		Qwen3-4B		Qwen3-8B		Qwen3-14B		Qwen3-32B	
Experiment			healthy_to_toxic	toxic_to_healthy	healthy_to_toxic	toxic_to_healthy	healthy_to_toxic	toxic_to_healthy	healthy_to_toxic	toxic_to_healthy	healthy_to_toxic	toxic_to_healthy
Group	Probe	Dataset										
a	LRProbe	c	-0.02	-0.02	-0.01	0.0	-0.01	-0.01	0.01	0.01	0.06	-0.01
		cn	-0.02	-0.02	-0.01	0.0	-0.0	-0.0	-0.0	0.0	0.06	-0.02
		g	0.08	0.02	-0.01	0.01	-0.01	0.0	0.01	0.01	0.03	0.05
		gn	0.03	0.0	-0.02	0.01	-0.0	-0.0	-0.0	-0.0	0.05	0.0
		h	0.02	0.0	-0.01	-0.01	0.0	0.0	0.01	0.02	-0.01	0.04
		hc	-0.05	0.0	-0.05	0.0	-0.0	-0.0	0.0	0.02	-0.02	0.03
		hs	-0.0	0.0	-0.01	0.01	-0.0	0.0	0.01	0.03	0.0	0.14
	MMProbe	c	0.09	0.12	0.04	0.13	0.05	0.05	-0.0	0.07	-0.0	0.02
		cn	0.06	0.06	-0.04	0.04	-0.03	0.01	-0.0	0.06	-0.01	0.02
		g	0.22	0.22	0.18	0.37	0.01	0.16	0.01	0.75	-0.0	0.01
		gn	0.05	0.18	0.05	0.2	-0.02	0.07	0.03	0.44	0.01	0.02
		h	-0.22	0.06	-0.06	0.03	-0.07	0.01	0.02	0.04	0.01	0.22
		hc	-0.12	0.05	-0.01	-0.02	-0.01	0.13	-0.04	0.55	0.0	0.04
		hs	-0.22	0.03	-0.01	0.03	-0.01	0.01	0.03	0.07	0.02	0.05
b2	LRProbe	c	-0.02	0.0	-0.01	0.0	0.04	0.01	-0.01	-0.01	0.01	-0.0
		cn	0.03	0.0	-0.01	-0.0	0.02	0.0	0.01	0.01	-0.0	-0.01
		g	0.02	0.0	-0.02	0.0	0.11	0.03	0.02	0.04	-0.01	0.0
		gn	0.02	0.0	-0.06	-0.02	-0.02	-0.01	-0.01	-0.02	-0.03	-0.02
		h	0.02	0.0	0.04	0.01	0.04	0.03	0.04	0.06	0.04	0.03
		hc	0.15	0.06	0.18	0.19	0.21	1.17	0.13	0.18	0.11	0.18
		hs	0.08	0.02	0.08	0.04	0.21	0.0	0.16	0.29	0.2	0.11
	MMProbe	c	-0.0	0.03	-0.02	-0.01	0.05	0.04	0.03	0.11	0.08	0.08
		cn	-0.09	-0.05	-0.06	-0.03	0.04	-0.04	-0.01	0.03	0.04	0.02
		g	0.22	0.25	0.06	0.11	0.18	0.56	0.07	0.37	0.09	0.19
		gn	0.15	0.14	-0.03	-0.01	0.13	0.02	0.01	0.1	0.01	0.01
		h	0.29	0.22	0.15	1.19	0.03	1.53	0.01	0.98	0.07	0.67
		hc	0.11	0.29	-0.04	0.53	0.0	1.12	0.02	0.72	0.04	0.73
		hs	0.48	0.29	0.14	1.2	0.04	1.53	0.02	0.92	0.07	0.6